INFORME TÉCNICO DE IMPLEMENTACIÓN: DETECCIÓN DE FRAUDE BANCARIO MEDIANTE EL MODELO KDD

Autor: Humberto Malavassi Campos
Fecha: Octubre, 2026

SECCIÓN 1: RESUMEN EJECUTIVO

1.1 Introducción y Contexto Organizacional

En la era de la banca abierta y la digitalización, el fraude financiero se ha convertido en una amenaza altamente sofisticada que evoluciona en fracciones de segundo. Para la institución bancaria, la prevención del fraude no es únicamente un imperativo de control de pérdidas, sino un pilar fundamental para salvaguardar la confianza de nuestros clientes y proteger la reputación corporativa en el mercado.

Este proyecto detalla el desarrollo, la implementación y la validación de un sistema predictivo inteligente entrenado sobre una muestra histórica de 5,000 transacciones, estructurado bajo el estándar riguroso de la metodología de Descubrimiento de Conocimiento en Bases de Datos (KDD).

1.2 La Realidad Analítica: El Desbalance Extremo de Clases

Uno de los mayores desafíos técnicos en la detección de fraude es el desbalance inherente de los datos. En nuestra población original de transacciones, se registró una tasa global de fraude del 2.18% (representando únicamente 109 transacciones fraudulentas frente a 4,891 transacciones legítimas).

Si implementáramos un sistema de reglas ingenuo que simplemente clasificara todas las transacciones como 'No Fraude', el sistema reportaría una exactitud teórica (Accuracy) del 97.82%. Sin embargo, este modelo hipotético sería completamente inútil desde el punto de vista del negocio, ya que dejaría pasar el 100% de los ataques, exponiendo al banco a pérdidas financieras críticas.

1.3 El Costo Financiero de los Errores (Trade-off de Negocio)

En nuestro modelo operativo, los dos tipos de errores analíticos tienen un costo financiero radicalmente asimétrico:

- **Falso Positivo (FP - Error de Tipo I):** El modelo clasifica preventivamente una transacción legítima como fraude. Esto genera fricción en el usuario final, requiriendo llamadas de soporte o verificación vía SMS/App. El costo operativo asociado es bajo y manejable.

- **Falso Negativo (FN - Error de Tipo II):** El modelo clasifica un fraude activo como transacción normal. El atacante sustrae los fondos, obligando a la institución a asumir el costo del reembolso por contracargo, además de mermar drásticamente la confianza del cliente. El costo financiero asociado es extremo.

El objetivo primario de este desarrollo es minimizar el costo asimétrico global maximizando la sensibilidad de captación (Recall), manteniendo los falsos positivos bajo un límite de tolerancia que no sature las colas del equipo de soporte de seguridad.

SECCIÓN 2: PROCESO KDD - SELECCIÓN Y PREPROCESAMIENTO

2.1 Fase de Selección: Curación de Variables

Para construir un modelo con alta capacidad de generalización y evitar el fenómeno de fuga de datos, se evaluó el rol predictivo de cada columna del dataset original:

- **Variables Excluidas:** Se descartaron id_transaccion e id_cliente debido a que actúan únicamente como identificadores únicos y no aportan patrones predictivos estructurales. Adicionalmente, se eliminó la variable estado_transaccion, ya que esta se cambia después del evento de fraude, y al incorporarla causaría un sesgo artificial.
- **Variables Seleccionadas:** Se incluyeron fecha_hora, edad_cliente, antiguedad_cuenta_meses, tipo_transaccion, monto, canal y region.

2.2 Fase de Preprocesamiento: Tratamiento de Datos Faltantes

El diagnóstico inicial reveló nulos menores: edad_cliente (1.42%), canal (1.18%) y region (1.58%). La estrategia de imputación se ejecutó de forma justificada para no distorsionar las distribuciones subyacentes:

- **La edad del cliente** fue imputada utilizando la mediana (40.0 años), garantizando inmunidad a la influencia de sesgos demográficos extremos.
- **Las variables categóricas canal y región** fueron imputadas empleando la moda ('App móvil' y 'San José' respectivamente), preservando la integridad sin ruidos artificiales.

2.3 El Dilema de los Outliers en el Monto

La aplicación del método del Rango Intercuartílico (IQR con factor k=1.5) sobre el monto transaccionado estableció un límite superior técnico en $379.91 USD, catalogando a 584 registros como outliers. El análisis arrojó:

Tasa de fraude en Outliers de Monto = 13.87% | Tasa de fraude en Rango Normal = 0.63%

La tasa de fraude en los outliers es 22 veces superior al rango común. Eliminar estas filas del entrenamiento para 'limpiar' el dataset hubiera privado a los clasificadores de los patrones

transaccionales más críticos. Se decidió conservar los outliers y suavizarlos con la transformación: monto_log = ln(monto + 1).

SECCIÓN 3: METODOLOGÍA DE TRANSFORMACIÓN E INGENIERÍA DE VARIABLES

3.1 Ingeniería de Variables (Features) Orientadas al Negocio

Se construyeron tres variables predictoras derivadas para capturar dinámicas del fraude:

- **hora_dia:** Obtenida a partir de la descomposición de la variable temporal fecha_hora.
- **es_noche:** Indicador binario (1 si ocurre entre las 22:00 y las 05:00 horas). Horarios nocturnos aprovechan la inactividad de alertas inmediatas del cliente.
- **monto_por_edad:** Ratio matemático que vincula la capacidad económica típica de un segmento de edad con la magnitud transaccionada.

3.2 Pipeline de Transformación de Alto Rendimiento

Para blindar la validación contra fugas de datos, se configuró una división estratificada 80/20 y un ColumnTransformer unificado:

- **Variables Numéricas:** Escalado por desviación estándar (StandardScaler).
- **Variables Categóricas:** Codificación One-Hot empleando drop='first' para prevenir multicolinealidad perfecta.

SECCIÓN 4: MINERÍA DE DATOS - ANÁLISIS NO SUPERVISADO

4.1 Segmentación de Clientes con K-Means

Entrenamos K-Means para un rango de k entre 2 y 10. El análisis gráfico del Método del Codo junto con el Coeficiente de Silueta determinaron que k=3 es la agrupación óptima (Silueta promedio general: 0.2162). El Clúster 1 concentra transacciones de bajo riesgo, mientras que el Clúster 2 consolida transacciones de alta variabilidad.

4.2 DBSCAN: Detección de Anomalías

Aplicamos un modelo espacial DBSCAN parametrizado con eps=3.0 y min_samples=10. El modelo etiquetó como anomalía extrema al 0.78% de la muestra. Al cruzar con la realidad, el 61.29% de estos puntos anomalías eran fraudes confirmados, capturando de forma no supervisada el 21.84% de todos los fraudes.

4.3 Reducción de Dimensionalidad con PCA

Dos componentes principales explican el 37.81% de la varianza acumulada, mientras que tres componentes alcanzan el 50.68%. La proyección bidimensional de las componentes demuestra visualmente que los fraudes se alinean en las fronteras externas de las agrupaciones normales.

SECCIÓN 5: MINERÍA DE DATOS - COMPORTAMIENTO PREDICTIVO SUPERVISADO

Comparamos la Regresión Logística (class_weight='balanced') contra Random Forest (class_weight='balanced_subsample') en el conjunto de prueba (1,000 registros):

Métrica Evaluada	Regresión Logística (Balanced)	Random Forest (Balanced)
Accuracy	83.80%	99.50%
Precision	10.67%	100.00%
Recall	86.36%	77.27%
F1-Score	0.1900	0.8718
AUC-ROC	0.9082	0.8966
Falsos Positivos (FP)	159	0
Falsos Negativos (FN)	3	5

SECCIÓN 6: INTERPRETACIÓN DE RESULTADOS Y MODELO SELECCIONADO

6.1 Elección de Modelo Campeón: Regresión Logística

A pesar de la precisión perfecta del Random Forest, se selecciona formalmente la Regresión Logística (Balanced) como el modelo campeón por tres pilares de gestión de riesgos:

- **Minimización de Pérdidas de Capital:** La Regresión Logística dejó escapar únicamente 3 fraudes (Falsos Negativos) frente a los 5 del Random Forest. Esta diferencia de error representa un ahorro neto sustancial para el banco.
- **Poder de Discriminación Superior:** La Regresión Logística alcanza un AUC-ROC del 0.9082, demostrando una separación probabilística superior.
- **Transparencia Regulatoria:** El modelo nos provee coeficientes interpretables y directos para justificar los bloqueos ante auditorías internas y entidades gubernamentales.

6.2 Interpretación de Variables Críticas de Riesgo

La característica con mayor nivel de importancia es monto_por_edad, seguida por monto_log y es_noche. Esto demuestra la lógica de negocio de que el fraude se define de forma no lineal al evaluar montos inusualmente costosos según el rango de edad y en horarios de alta vulnerabilidad nocturna.

SECCIÓN 7: LIMITACIONES Y TRABAJO FUTURO

Se proponen tres áreas clave para la futura optimización de la prevención del fraude:

- **Inclusión de Datos Georreferenciados:** Cálculo automatizado de la velocidad de desplazamiento geográfico entre transacciones sucesivas para evitar fraudes inmediatos en diferentes puntos físicos.
- **Modelos de Aprendizaje Activo:** Re-entrenamiento adaptativo del modelo según la confirmación rápida del cliente sobre alertas de falsos positivos.
- **Huella Digital de Sesión:** Incorporación de variables como dirección IP, tipo de dispositivo y sistema operativo para aislar anomalías de accesos electrónicos.